

Introdução à Inferência Causal

Resultados Potenciais

Fernando Meireles
IESP-UERJ

Agosto, 2019

Efeitos e suas causas

Relações de causa e efeito são vistas em todo o lugar. Se eu derrubo meu *laptop* de uma certa altura, ele cai e quebra.

A queda é a causa da quebra.

Obviamente, vocês não precisam de um curso para aprender isso.

Causas e seus efeitos

Estudar
causalidade é,
por definição,
estudar o que
não **não**
aconteceu

- Se meu *laptop* não tivesse caído ele estaria intacto?
- Se eu tivesse investido em *bitcoins* há 5 anos, hoje eu estaria rico?
- Se a crise econômica de 2008 nunca tivesse ocorrido, Donald Trump seria hoje o Presidente dos Estados Unidos?

Precisamos estudar isso?

As alternativas

Se quisermos entender como fenômenos complexos — desigualdade, violência urbana, corrupção, entre inúmeros outros — surgem ou desaparecem, *precisamos ser capazes de testar afirmações causais.*

Conhecimento causal

Correlação não é causalidade, mas não é disso que estamos tratando.

Tipos de inferência

Preditiva: Sobre o futuro

Descritiva: Sobre estruturas

Classificatórias: Sobre pertencimentos

Causal: Sobre **contrafactuais**

Motivação

Questões causais

A maioria das **questões** que importam para nós são de **natureza causal**

- Corrupção na gestão educacional afeta o ensino dos(as) alunos(as) (e.g., Ferraz, Finan, and Moreira, 2012)?
- Programas de transferência condicionada de renda melhoram a qualidade de vida da população (e.g., Galiani and McEwan, 2013) ?
- Casos de violência em larga escala no passado afetam o compartamentos das pessoas no presente (e.g., Lupu and Peisakhin, 2017) ?
- Guerras promovem a integração de imigrantes (e.g., Lupu and Peisakhin, 2017) ?
- Os discursos de Hitler contribuiriam para a ascensão eleitoral do Partido Nacional Socialista (Selb and Munzert, 2018) ?

Impacto real

- Mudar geograficamente para locais pobres afeta decisivamente o futuro de uma criança
 - Sabemos disso graças a [Chetty et al. \(2016\)](#);
- Censurar ações coletivas, e não protestos individuais, é a melhor forma de manter um regime autoritário
 - [King et al. \(2013\)](#) mostraram isso.


Revolução de credibilidade

Em números


De Druckman et al. (2006):

FIGURE 1. “Experimental” Trends in the Review


References to Experiments as Empirical Tests




References to Experiments as Institutional Innovations




References to Experiments as Studies with Randomized Trials (excluding experimental articles)



Experimental Articles



O estudo de causa e efeito se espalhou entre disciplinas



Objetivo

Nosso objetivo neste curso é precisamente introduzir um conjunto de ferramentas que nos permitem falar, e principalmente analisar, afirmações causais.

Plano desta aula

Resultados Potenciais

Precisamos de uma base comum para discutirmos efeitos causais que seja rigorosa e simples.

Isso é o que cobriremos hoje.

Mas, antes, precisamos discutir também:

- *Nosso percurso*: resultados potenciais, DAGS, experimentos, experimentos naturais e outras estratégias comuns;
- *Método*: R, estatística básica, exercícios e tarefas;
- *Expectativas*: Não veremos tudo, mas entraremos no percurso principal.

Contrafactuais

Dois casos, múltiplos cenários

Obviamente, não podemos observar os dois cenários simultaneamente. Se *Fulano* estudar, e se *Ciclano* não, a comparação direta entre eles leva ao resultado contrário.

Nome	Estudou	Não estudou	Resultado
<i>Fulano</i>	6	?	?
<i>Ciclano</i>	?	7	?

$$6 - 7 = -1$$

Contrafactualidade

O **problema central** de estudar causalidade é resolver essa falta do **cenário alternativo**, do **contrafactual**

Como só observamos um cenário para cada indivíduo, compará-los diretamente não nos permite saber se estudar causa um aumento nas notas. Precisamos de ferramentas.

Resultados Potenciais

O *Framework*

Podemos avançar no estudo de contrafactuais colocando o problema em termos mais claros. Usaremos o chamado **Modelo de Resultados Potenciais**, desenvolvido originalmente por Neyman e expandido por D. Rubin, entre outros (e popularizado por Holland).

A ideia central dele é fornecer uma base para *identificar* certas quantias.

Preliminares

Alguma notação antes de avançarmos

- Digamos que a nota de *Fulano* quando ele estudou seja denotada por $Y_i(1)$;
- E, quando ele não estudou, por $Y_i(0)$;
- Estudar ou não pode ser indicado por D_i (e.g., $D_i = 1$ se estudou);
- E indica um valor esperado e, $|$, uma relação condicional.

Problema

Temos um tratamento D , também chamado de intervenção ou causa, e queremos saber o que acontece em alguma unidade quando ela submetida a esse tratamento.

Queremos saber, no nível individual, quanto é $Y_i(1) - Y_i(0)$, ou

$$\begin{aligned}\tau_i &= [Y_i(1)|D_i = 1] - [Y_i(0)|D_i = 0] \\ &= [Y_i|D_i = 1] - [Y_i|D_i = 0]\end{aligned}$$

A ausência de contrafactuais

Resultados potenciais nada mais são do que os cenários possíveis para a unidade i (i.e., $Y_i(1)$ e $Y_i(0)$).

Mas, como vimos, só observamos um deles.

Problema fundamental da inferência causal

Não podemos observar diferentes resultados potenciais de uma mesma unidade.

Como contornamos isso?

Pressupostos de identificação

Uma **quantia é identificada** quando, com dados infinitos, conseguimos estimar um valor fixo para ela. Isso depende **pressupostos**.

- Homogeneidade;
- Ignorabilidade (ou *exchangeability*, em inglês).

Solução do *framework*

Quando um tratamento D é **independente** dos resultados potenciais Y , uma quantia pode ser identificada comparando grupos

- Basta comparar grupos de médias;
- O exemplo de ouro é o experimento, no qual o mecanismo de seleção é aleatório.

Efeito médio

Enquanto que um efeito causal individual não pode ser calculado, podemos usar esse pressupostos de *ignorability* (mais alguns, que veremos) para estimar diferenças de médias entre tratados e não tratados.

Vários casos, dois cenários

Vamos voltar ao problema da prova, agora com mais observações.

Nome	Estudou	Não estudou	Resultado
<i>Fulano</i>	6	?	?
<i>Ciclano</i>	?	6	?
<i>Ciclano</i>	?	4	?
<i>Ciclano</i>	8	?	?
<i>Ciclano</i>	?	2	?
<i>Ciclano</i>	4	?	?

$$E[\tau_i] = E[Y_i|D_i = 1] - E[Y_i|D_i = 0]$$

$$E[\tau_i] = \frac{1}{3}(6 + 8 + 4) - \frac{1}{3}(6 + 4 + 2)$$

$$E[\tau_i] = 2$$

Identificação

Uma ciência da identificação

- Em modelagem, a prática é reproduzir o Processo Gerador de Dados (PGD), o que nos leva a escolher formas de estimação e de inferência;
- Identificação depende, ao contrário, de um desenho, o que nos permite adotar estimadores simples (como diferença de médias).

Modelo \rightsquigarrow Estimação \rightsquigarrow Inferência

Desenho \rightsquigarrow Estimação \rightsquigarrow Inferência

Observações

A especificidade da inferência causal

- Na classificação, queremos usar X_i para descobrir Z_i ;
- Para fazer previsões, queremos apenas saber o valor de Y_i com base nos valores de X_i ;
- Na inferência causal, queremos saber qual valor Y_i assumirá se alterarmos D_i .

Identificação e pressupostos

O importante a reter, enfim, é que **identificação** de efeitos causais depende centralmente de pressupostos, e não de técnicas ou modelos.

Quando falamos de **estratégia de identificação**, estamos falando:

- Quais pressupostos, fora estimação, para explorar o mecanismo de seleção ao tratamento, nos permitem fazer afirmações causais com os dados que temos?

Viés de seleção

Na ausência de **ignorability**, comparar unidades com tratamentos diferentes pode resultar em **viés de seleção**

- Hospital mata pessoas (e.g., se fui parar no hospital, minha saúde não estava boa previamente);
- Dinheiro pode não trazer votos (e.g., se eu tenho votos, consigo dinheiro);
- Educação pode não aumentar renda (e.g., se eu me eduquei, provavelmente tinha tempo livre e dinheiro).

Pausa para usar o R

Vamos analisar os dados de (LaLonde, 1986), sobre o efeito de um programa de treinamento profissional sobre os salários de trabalhadores americanos.

- Dados:
 - 445 observações e 12 variáveis;
 - `nsw` é o indicador de tratamento, D ;
 - A variável de interesse é `re87` (salário em 1978, depois da intervenção).

Referências

Ferraz, C, F. Finan, and D. B. Moreira (2012). "Corrupting learning: Evidence from missing federal education funds in Brazil". In: *Journal of Public Economics* 96.9-10, pp. 712-726.

Galiani, S. and P. J. McEwan (2013). "The heterogeneous impact of conditional cash transfers". In: *Journal of Public Economics* 103, pp. 85-96.

LaLonde, R. J. (1986). "Evaluating the econometric evaluations of training programs with experimental data". In: *The American economic review*, pp. 604-620.

Lupu, N. and L. Peisakhin (2017). "The legacy of political violence across generations". In: *American Journal of Political Science* 61.4, pp. 836-851.

Selb, P. and S. Munzert (2018). "Examining a most likely case for strong campaign effects: Hitler's speeches and the rise of the Nazi party, 1927-1933". In: *American Political Science Review* 112.4, pp. 1050-1066.